

DATA ENGINEERING UND WRANGLING

Abflugverspätungen am Flughafen Zürich

Autoren

Yves Bornhauser, Elia Geromin

Modul

Data Engineering und Wrangling

Datum

03.06.2026

FHNW Hochschule für Wirtschaft

BSc Business Artificial Intelligence

Inhaltsverzeichnis

1. Einleitung und Fragestellung	3
1.1 Projektziel.....	3
1.2 Fragestellungen.....	3
1.3 Annahmen und Limitierungen	3
2. Datenerhebung und Quellensuche	4
2.1 Daten.....	4
3. Explorative Datenanalyse und Qualitätsprüfung.....	6
3.1 Erste Analyse	6
3.2 Qualitätscheck.....	6
3.3 Visualisierung des Ist-Zustands	9
4. Datenbereinigung.....	11
4.1 Missing Values	11
4.2 Ausreisserbehandlung.....	12
4.3 Datentypen	12
5. Datenintegration und Harmonisierung	13
5.1 Zusammenführung	13
5.2 Harmonisierung	13
6. Feature Engineering und Transformation	14
6.1 Feature-Erstellung.....	14
6.2 Datenpipeline und Architektur	14
7. Analyse	15
7.1 Korrelationsanalyse.....	15
7.2 Analyse des Einflusses der Temperatur.....	17
7.3 Analyse des Einflusses der Nutzung der verschiedenen Pisten	18
7.4 Analyse des Einflusses der Wochentage/Monate	20
7.5 Analyse des Einflusses des WEFs.....	22
7.6 Analyse des Einflusses des Ölpreises	22
8. Beantwortung Fragestellungen	24
8.1 Beantwortung der Fragestellungen	24
9. Fazit und Reflexion	25
9.1 Zusammenfassung.....	25
9.2 Lessons Learned	25
10. Verwendung von generativer KI.....	26
11. Abbildungsverzeichnis	27

1. Einleitung und Fragestellung

1.1 Projektziel

Unser Ziel ist es zu untersuchen, was effektiv Einfluss auf Verspätungen am Flughafen Zürich hat. Dabei wollen wir nicht nur klassische, sondern auf den ersten Blick auch stark unabhängige mögliche Zusammenhänge untersuchen. Basierend darauf möchten wir später auch ein Machine-Learning-Modell bauen können, welches vorhersagen kann, wie gross die Verspätung am morgigen Tag ist. Damit könnte der Flughafen Zürich Gästen schon früh kommunizieren, was sie erwartet und wann sie am Flughafen sein sollten.

Allerdings beschränken wir uns in Bezug auf die Analyse der Daten nicht auf Daten, die auch zum Machine Learning effektiv genutzt werden könnten. Konkret werden wir auch Daten hinzufügen, die nicht schon am Vortag verfügbar sind und somit nicht in der Praxis für Machine Learning genutzt werden können (Data Leakage). Trotzdem möchten wir interessante Korrelationen mit diesen Daten analysieren.

1.2 Fragestellungen

- Welche Faktoren haben den grössten Einfluss auf Verspätungen am Flughafen Zürich?
- Welche Zusammenhänge gibt es zwischen den verschiedenen Daten, die Einfluss auf die Verspätungen haben und was kann man daraus schliessen?
- Welchen Einfluss hat das WEF tatsächlich auf Verspätungen und den Flugverkehr?
- Was könnte der Flughafen Zürich tun, um Verspätungen an Tagen mit grosser Verspätung zu reduzieren?
- Wie gut kann ein Machine-Learning-Modell die Verspätungen tatsächlich vorhersagen?

1.3 Annahmen und Limitierungen

Bei der Interpretation dieser Analyse sollten mehrere Annahmen berücksichtigt werden. Erstens wird angenommen, dass die Daten der genutzten Wetterstation repräsentativ für den Flughafen Zürich sind. Dies sollte allerdings gegeben sein, da die Station sich direkt bei einer Piste des Flughafens befindet und anscheinend auch vom Flughafen Zürich betrieben wird. Zudem wird angenommen, dass eine tägliche Aggregation der Daten sinnvoll ist. Weiter wird angenommen, dass die Durchschnittsverspätung von Eurocontrol den Zustand des Flughafens Zürich angemessen abbildet. Auch, dass die gescrapten Wikipedia-Daten korrekt sind, wird angenommen. Zuletzt wird angenommen, dass die zusammengeführten Quellen korrekt synchronisiert wurden.

Die Analyse weist auch verschiedene Limitierungen auf. Es können Datenlücken bei den Wetter- oder Ölpreisangaben entstehen, die durch fehlende Werte in der Analyse dargestellt werden. Der Analysezeitraum von 2019 bis 2026 ist relativ begrenzt und könnte längerfristige Trends nicht vollständig abbilden. Die COVID-19-Pandemie hat erhebliche Auswirkungen auf den Flugverkehr gehabt und könnte die Daten verzerren. Bei der Analyse haben wir bewusst mit Daten ab dem Januar 2022 begonnen, da sich die COVID-Situation ab dann normalisierte und der Flugverkehr wieder einigermaßen normal aufgenommen wurde. Schliesslich ist wichtig zu betonen, dass diese Analyse Korrelationen aufdeckt, die Kausalität ist aber deswegen nicht zwingend gegeben. Deshalb haben wir bestmöglich versucht, Korrelationen/externe Effekte in unsere Analyse einfließen zu lassen.

2. Datenerhebung und Quellensuche

Wir haben bewusst auf Daten gesetzt, die sich ergänzen bzw. komplementieren. Der Fokus liegt also auf dem Zusammenführen und Auswerten der verschiedenen Daten und nicht auf der Harmonisierung von Quellen mit gleichem Inhalt.

2.1 Daten

Airports Punctuality

Eine unserer beiden Hauptdatenquellen ist eine Excel-Datei namens «Airports_Punctuality.xlsx», die durchschnittliche Abflugverspätungen von mehreren europäischen Flughäfen enthält. Diese Datei wird von Eurocontrol bereitgestellt und enthält unter anderem die durchschnittliche tägliche Verspätung vom Flughafen Zürich. Diese Daten sind für uns die relevantesten Daten, da wir Korrelationen etc. zu diesen Daten ziehen können.

- Quelle: <https://www.eurocontrol.int/Economics/DailyPunctuality-Airports.html>
- Format: XLSX-Datei
- Import: Mittels der «read_excel» Funktion von pandas, als Data Frame gespeichert

Abflüge Flughafen Zürich

Dieser Datensatz sagt aus, wie viele Abflüge es vom Flughafen Zürich an einem jeweiligen Tag gab. Problematisch war hierbei allerdings, dass diese Daten nur als PDF zur Verfügung standen. Deshalb haben wir mit Unterstützung von Codex mit der Library «pdfplumber» eine CSV erstellt, die die Daten im PDF in eine CSV umgewandelt hat. Auch die Anzahl der Abflüge pro Piste haben wir hieraus exportiert, da es interessant sein könnte, zu wissen, ob die Nutzung einer spezifischen Piste zu mehr Verspätungen führen könnte. Um zu verifizieren, dass die Daten korrekt sind, wurde eine Logik in das Skript eingebaut, die prüft, ob alle Abflüge von allen Pisten zusammen genau die Anzahl Abflüge des gesamten Tages ergeben. Zusätzlich haben wir nach dem Ausführen des Skripts punktuell überprüft, ob die Daten in der CSV mit den Daten im PDF übereinstimmten, was der Fall war.

- Quelle: [Bewegungsstatistik Flughafen Zürich](#) (Link ändert sich teilweise, kann also sein, dass er zum Zeitpunkt der Sichtung des Berichts nicht mehr funktioniert)
- Format: Ursprünglich PDF, umgewandelt in eine CSV
- Import: Mittels der «read_csv» Funktion von pandas, als Data Frame gespeichert

Wetterdaten Flughafen Zürich

Dieser Datensatz enthält diverse Wetterdaten von einer Wetterstation direkt bei einer Piste vom Flughafen Zürich. Auf der Website von meteostat konnten direkt alle historischen Daten heruntergeladen werden. Wir haben diese ab dem Januar 2022 als CSV heruntergeladen.

- Quelle: <https://meteostat.net/en/station/06670>
- Format: Direkter Download als CSV
- Import: Mittels der «read_csv» Funktion von pandas, als Data Frame gespeichert

Schneedaten

Die Daten der Wetterstation vom Flughafen Zürich enthielten leider keine Daten zum Schneefall. Deshalb haben wir anhand der vorhandenen Daten eine neue Spalte erstellt. Die Spalte übernimmt automatisch den Wert der Regenintensität, wenn die Temperatur unter 2 Grad ist, da sich ab dann Schnee bilden kann. Allerdings müssen diese Daten vorsichtig beachtet werden, da wir nur die tägliche Durchschnittstemperatur hatten und somit auch an Tagen mit höheren Durchschnittstemperaturen Schnee hätte fallen können.

- Quelle: Abgeleitet von Wetterdaten (Meteostat)
- Format: Erzeugung einer neuen Spalte im Wetter data frame
- Import: -

Ölpreise

Um zu schauen, welchen Einfluss der Ölpreis auf die Verspätungen hat, wurden die täglichen Ölpreise der FRED als CSV heruntergeladen. Wir haben gezielt den Brent-Ölpreis verwendet, da dieser für Europa am relevantesten ist.

- Quelle: <https://fred.stlouisfed.org/series/DCOILBRETEU>
- Format: Direkter Download als CSV
- Import: Mittels der «read_csv» Funktion von pandas, als Data Frame gespeichert

Feiertage

Bekanntlich verreisen viele Leute während Feiertagen, allerdings hat jeder Kanton in der Schweiz unterschiedliche Feiertage. Deshalb haben wir uns entschieden, die nationalen Feiertage und die des Kanton Zürich als Feiertage zu deklarieren, da der Flughafen Zürich im Kanton Zürich liegt und dies auch der bevölkerungsreichste Kanton ist. Die Daten wurden mit der Python-Library «holidays» gespeichert und für jedes Datum wurde geschaut, ob es ein Feiertag war. Daraus erstellten wir dann eine neue Spalte, die true/false als Werte hat und aussagt, ob das Datum ein Feiertag ist oder nicht.

- Quelle: holiday Library in Python
- Format: -
- Import: -

WEF

Um die historischen Daten der WEFs zu erhalten, haben wir mithilfe von Codex und BeautifulSoup einen Scraper erstellt, der die vergangenen Daten direkt von Wikipedia scraped. Daraus erstellten wir dann wieder eine neue Spalte, die true/false als Werte hat und aussagt, ob das Datum während eines WEFs war oder nicht.

- Quelle: https://en.wikipedia.org/wiki/World_Economic_Forum
- Format: Python-Liste
- Import: -

Weitere Ideen für Daten

Wir hätten gerne noch einige weitere Daten hinzugefügt, die wir leider nicht öffentlich und kostenlos finden konnten. Eine Idee war zum Beispiel, die Anzahl der Flugzeuge, die am Flughafen zu einer Uhrzeit herumstehen, mit Computer Vision und Satellitenbildern zu zählen, allerdings waren die kostenlosen Satellitenbilder zu unscharf und historisch nicht kostenlos verfügbar. Eine weitere Idee war es, die Verspätungen der SBB und die Stauzeiten rund um den Flughafen Zürich zu zählen. Hier gab es zwar aktuelle Daten, aber leider keine historischen Daten. Auch die Sperrungen von Lufträumen wären interessant gewesen miteinzubeziehen, dies hätte aber die Komplexität extrem gesteigert.

3. Explorative Datenanalyse und Qualitätsprüfung

3.1 Erste Analyse

Alle Daten wurden spätestens ab dem 01.01.2022 erhoben und sind mindestens täglich vorhanden. Die Daten reichen alle mindestens bis zum 28.02.2026, dies ist der Endpunkt, wo wir aufhören, Daten zusammenzuführen. Somit wird der zusammengeführte Datensatz zum Ende 1520 Zeilen enthalten. Die in der Datenerhebung erwähnten Daten werden noch hinsichtlich ihrer Datentypen eingeordnet:

Qualitativ nominale Daten

- Wetterdaten, schnee_vorhanden: Enthält nur True/False ob an dem Tag Schnee fiel
- Feiertage: Enthält nur True/False ob an diesem Tag ein Feiertag ist
- WEF: Enthält nur True/False ob an diesem Tag das WEF stattgefunden hat

Quantitativ diskrete Daten

- Abflüge Flughafen Zürich: Enthält Anzahl Abflüge pro Tag vom Flughafen Zürich, immer ganze positive Zahlen, da es keine halben Abflüge gibt
- Alle Spalten mit Abflügen pro Piste pro Tag, immer ganze positive Zahlen, da es keine halben Abflüge gibt

Quantitativ kontinuierliche Daten

- Airports Punctuality, Abflugverspätung ZRH: Enthält im ursprünglichen Datensatz Verspätungen von allen Flughäfen, nach Selektion der Daten, nur noch durchschnittliche Abflugverspätung pro Flug, pro Tag in Minuten am Flughafen Zürich, kann jegliche positive, in Ausnahmefällen auch negative Werte annehmen (wenn Flieger zu früh abheben), mit Kommastellen
- Wetterdaten, Regen: Enthält die Regenmenge (mm) pro Tag, kann theoretisch jegliche positive Werte annehmen, mit Kommastellen
- Wetterdaten, Windgeschwindigkeit: Enthält die durchschnittliche Windgeschwindigkeit pro Tag (km/h), kann theoretisch jegliche positive Werte annehmen, mit Kommastellen
- Wetterdaten, maximale Windgeschwindigkeit: Enthält die höchste gemessene Windgeschwindigkeit an einem Tag (km/h), kann theoretisch jegliche Werte annehmen, mit Kommastellen
- Wetterdaten, Temperatur: Enthält Durchschnittstemperatur pro Tag, kann theoretisch jegliche positive Werte annehmen, mit Kommastellen
- Wetterdaten, Schnee Intensität: Enthält Schneefallmenge pro Tag (abgeleitet von Regen und Temperatur, Erklärung siehe Teil Datenerhebung), kann theoretisch jegliche positive Werte annehmen, mit Kommastellen
- Ölpreise: Enthält Ölpreis pro Tag (Brent, USD), kann jegliche positive, in Ausnahmefällen auch negative Werte annehmen, mit Kommastellen

3.2 Qualitätscheck

Um zu schauen, ob bei den Daten irgendwelche Datenpunkte fehlen oder Duplikate vorhanden sind, haben wir mithilfe von YData eine HTML-Datei generieren lassen, in der interaktiv die fehlenden Werte, Duplikate etc. angeschaut werden können. Die Tabelle unten zeigt die Erkenntnisse zu den jeweiligen Daten (nachvollziehbar sind sie in der HTML-Datei im Ordner Qualitätskontrolle).

Spalte	Eindeutige Werte	Fehlende Werte	Durchschnitt	Minimum (Anzahl False bei binären Spalten)	Maximum (Anzahl True bei binären Spalten)	Kommentar
Schnee (binär)	2	0	-	1465	55	Wie erwartet für binäre Spalte, relativ wenig Schnee
Feiertage (binär)	2	0	-	1478	42	Ca. 10 Feiertage pro Jahr sind korrekt
WEF (binär)	2	0	-	1495	25	5 WEFs waren in unserem Zeitraum, somit 5 Tage pro WEF, das ist korrekt
Abflüge Flughafen Zürich	241	0	334.8	144	444	Sieht alles sehr sinnvoll aus
Abflüge Piste 10	92	0	7.4	0	290	An 92 % der Tage nicht genutzt, aber trotzdem sehr hohes Maximum, sehr interessant
Abflüge Piste 16	69	0	30.9	0	72	An fast allen Tagen genutzt (97%), aber trotzdem maximale Abflüge pro Tag nur 72, liegt daran, dass diese für grosse Flugzeuge konzipiert ist
Abflüge Piste 28	294	0	208.6	0	335	Hauptpiste, sehr viele Abflüge, nur selten gar nicht genutzt (3%)
Abflüge Piste 32	281	0	82.8	2	407	Jeden einzelnen Tag genutzt, liegt daran, dass am Abend Flüge ab hier abfliegen
Abflüge Piste 34	25	0	5.1	0	25	Fast täglich genutzt (98%), aber trotzdem nur sehr wenige Abflüge insgesamt, sehr interessant

Abflugverspätung ZRH	1517	0	18.7	3.94	78.32	Hoher Ausreisser gegen oben, 3 Werte genau gleich, ist realistischer Zufall
Regen	189	10	2.7	0	52.3	An den meisten Tagen kein Regen ist sinnvoll, auch sonst realistisch
Windgeschwindigkeit	203	0	9.15	2.5	32.1	Wenig unterschiedliche Werte, liegt daran, dass Daten nur eine Kommastelle haben, sonst realistisch
Maximale Windgeschwindigkeit	104	12	34.1	11	106	104 verschiedene Werte nicht möglich bei diesem Minimum und Maximum, liegt daran, dass manchmal auf Kommastelle gerundet, manchmal nicht, sonst realistisch
Temperatur	301	0	10.9	-8.4	27	Alles sehr realistisch
Schnee Intensität	33	0	0.12	0	29.1	Wenige Schneetage wie schon bei binärer Spalte oben, sonst realistisch
Ölpreis	928	469	82.7	59.9	133.2	An 469 Tagen (30.9 %) fehlen die Daten, da am Wochenende und an Feiertagen kein Ölpreis mitgegeben wurde

Grundsätzlich lässt sich erkennen, dass wir von Beginn an eine sehr hohe Datenqualität haben. Es gibt keine Duplikate im gesamten Datensatz und nur 2.7 % aller Daten fehlen, diese sind auf lediglich 3 Spalten zurückzuführen. Für die fehlenden Daten muss noch eine Lösung gefunden werden.

Overview	Alerts 14	Reproduction
----------	-----------	--------------

Dataset statistics		Variable types	
Number of variables	12	DateTime	1
Number of observations	1520	Boolean	3
Missing cells	491	Numeric	8
Missing cells (%)	2.7%		
Duplicate rows	0		
Duplicate rows (%)	0.0%		
Total size in memory	111.5 KiB		
Average record size in memory	75.1 B		

Abbildung 1 Datensatz Statistik

3.3 Visualisierung des Ist-Zustands

Die Daten wurden oben grundsätzlich schon ein wenig analysiert, ob sie plausibel sind und wie die Verteilung aussieht. Trotzdem haben wir einige Spalten noch ein wenig genauer analysiert, da diese uns sehr interessant erschienen.

Die Verteilung der Verspätungen ist für uns sehr relevant, da dies die Spalte/das Feature ist, auf welche wir die Korrelationen untersuchen werden und worauf sich die meisten Fragestellungen beziehen, weshalb wir dafür ein Histogramm und einen Boxplot erstellt haben.




Abbildung 2 Verspätungen Ist-Zustand

Die Verteilung zeigt ein erwartbares Muster: 50 % der Tage liegen zwischen 13.3 und 22.3 Minuten Verspätung. Es gibt keinen einzigen Tag, an dem der durchschnittliche Flug zu früh abgeflogen ist. Allerdings gibt es einige Ausreisser nach oben. Dies ist durchaus logisch, da es in der Vergangenheit Tage mit IT-Pannen, extremem Wetter etc. gab. Der Median und Durchschnitt liegen sehr nahe beieinander, was an den wenigen Ausreissern und einer relativ symmetrischen Verteilung liegt.

Die Piste 10 ist uns schon stark bei der Qualitätskontrolle aufgefallen, weshalb wir diese Verteilung nochmals als Histogramm dargestellt haben, um sie genauer zu untersuchen. Es wurde hier zusätzlich eine Achsenunterbrechung hinzugefügt, da ansonsten kaum ein Muster erkennbar wäre.




Abbildung 3 Histogramm Piste 10

Die Verteilung spricht eine klare Sprache: Die Piste wird praktisch nie genutzt, und wenn sie genutzt wird, dann wird sie teilweise auch sehr intensiv genutzt. Nach einer kurzen Recherche im Internet zeigt sich, dass die Piste 10 bei Biswind (Nordostwind) genutzt wird (<https://www.flughafen-zuerich.ch/de/unternehmen/verantwortung/laerm-und-schallschutz/flugbetrieb/betriebskonzepte>). Da der Biswind eher selten stark vorhanden ist, erklärt es, wieso diese Piste selten genutzt wird, ein Fehler in den Daten ist also nicht vorhanden. Dies erklärt auch, dass die Piste manchmal intensiv und manchmal weniger intensiv genutzt wird, da die Bise manchmal nur eine Stunde dauert und teilweise auch einen ganzen Tag dauern kann. Allerdings stellt sich die Frage, wie sinnvoll es ist, diese Spalte zu verwenden, oder ob wir sie in eine binäre Spalte umwandeln. Gegen das Entfernen der Spalte spricht allerdings, dass sie potenziell sehr spannende Einflüsse auf die Verspätungen haben könnte.

Abschliessend haben wir die maximale Windgeschwindigkeit noch genauer begutachtet, da diese potenziell sehr viel Einfluss auf die Verspätungen haben könnte. Auch hierfür wurde wieder ein Histogramm erstellt.




Abbildung 4 Windgeschwindigkeiten

Ab ca. 60 km/h spricht man von einem stürmischen Wind (ab dann werden auch Abflüge für Flugzeuge schwerer bzw. verzögert). Interessant ist, dass 7.1% der Tage diesen Wert erreichen. Allerdings sprechen wir hier von einem höchsten gemessenen Wert, dies bedeutet keinesfalls, dass der Wind den ganzen Tag so stark war. Zusätzlich ist ersichtlich, dass der Grossteil der maximalen Windgeschwindigkeit sich zwischen 10 und 50 km/h bewegt. Diese Windgeschwindigkeiten sind für den Flugverkehr noch unproblematisch und sollten eigentlich keinen Einfluss auf den Flugverkehr haben. Daraus kann man grundsätzlich schliessen, dass die Verspätungen eher schwach mit dem Wind korrelieren werden, da der Einfluss erst ab ca. 60 km/h sichtbar wird.

4. Datenbereinigung

4.1 Missing Values

Wie schon beschrieben, hatten wir bei drei Spalten/Features fehlende Werte. Generell möchten wir so weit wie möglich darauf verzichten, Zeilen mit fehlenden Daten zu entfernen, da gerade diese Tage interessant sein könnten und generell nur wenige Daten fehlen. Aus diesen Gründen haben wir uns dazu entschieden, bei allen Daten Werte einzusetzen, die plausibel sein könnten. Um immer transparent aufzuzeigen, wann wir Daten imputiert haben, haben wir dafür neue Spalten erstellt, die zeigen, ob bei einem Datum einer Spalte etwas eingesetzt wurde.

Regen

Weil Regen nicht stark mit einer anderen Spalte korreliert, können wir die fehlenden Werte nicht aus anderen Daten ableiten, wie z. B. vom Tag davor oder danach. Wir haben uns bewusst dazu entschieden, den Modus zu verwenden (den Wert, der am meisten vorkommt), was in unserem Fall kein Regen (0) bedeutet. Alternativ hätte man ein Machine-Learning-Modell erstellen können oder den Durchschnitt einsetzen, aber insbesondere der Durchschnitt wäre voraussichtlich nicht plausibel gewesen und ein Machine-Learning-Modell wäre dem Nutzen daraus nicht gerecht geworden. Die Daten, die gefehlt haben, sind auf Fehler der Messanlage zurückzuführen, weil 10 zufällige (voneinander unabhängige) Tage gefehlt haben.

Maximale Windgeschwindigkeit

Die maximale Windgeschwindigkeit ist stark von der durchschnittlichen Windgeschwindigkeit abhängig, welche an keinem Tag gefehlt hat. Weil hier alle Daten vorhanden sind, haben wir uns dazu entschieden, das durchschnittliche Verhältnis von der durchschnittlichen Windgeschwindigkeit und der maximalen Windgeschwindigkeit von allen vorhandenen Daten auszurechnen und dies dann auf die fehlenden Werte anzuwenden. So haben wir sehr realitätsnahe und plausible Daten. Hätten wir z. B. den Median oder den Durchschnitt eingesetzt, bestünde die Möglichkeit, dass Werte auftauchen, die nicht sinnvoll sind (wie z. B. eine maximale Windgeschwindigkeit von 30 km/h bei einer durchschnittlichen Windgeschwindigkeit von 34 km/h an einem Tag). Diese Lösung war in Python auch relativ einfach umzusetzen und somit sehr lohnend.

Ölpreis

Der Ölpreis fehlt an jenen Tagen, die auf ein Wochenende oder einen Feiertag fallen. Das Einsetzen des Durchschnitts oder Medians ist daher aus unserer Sicht sinnlos, weil der Ölpreis stark schwankt. Um dieses Problem zu beheben, haben wir lange recherchiert und dabei herausgefunden, dass in der Finanzbranche ein sogenannter «forward fill» sehr üblich ist bei fehlenden Werten. Dies bedeutet, dass der letzte bekannte Ölpreis auf den leeren Tag übernommen wird. Auch logisch betrachtet ist dies sehr sinnvoll, da sich der Ölpreis am Wochenende/an Feiertagen stark am Vortagespreis orientiert. Dies lässt sich in Python sehr einfach mit der Funktion `ffill` von `pandas` umsetzen.

Um zu verifizieren, dass die imputierten Daten die ursprünglichen Daten nicht zu stark verzerren, haben wir ein kleines Skript gebaut, welches die Vorher- und Nachher-Daten mit folgendem Ergebnis vergleicht (Std. = Standardabweichung):

Spalte	Imputierte Anzahl Daten	Mittelwert vorher	Mittelwert nachher	Median vorher	Median nachher	Std. vorher	Std. nachher
regen	10	2.71	2.69	0	0	5.5	5.49
maximale_windgeschwindigkeit	12	34.05	34.04	31	31	15.26	15.21
oil_price	469	82.69	82.71	80.71	80.5	14.12	14.16

Die Auswertung zeigt klar, dass die Daten sich kaum verändert haben, und somit sind die imputierten Daten durchaus realistisch und verzerren die Ergebnisse nicht nennenswert. Auch der «forward fill» beim Ölpreis erweist sich als sehr geeignet. Obwohl 469 Tage imputiert wurden, verschieben sich der Median und der Durchschnitt kaum.

4.2 Ausreisserbehandlung

Auf das Entfernen und Skalieren von Ausreißern haben wir komplett verzichtet, da, wie schon beim Qualitätscheck beschrieben, alle Daten plausibel sind und gerade die Ausreißer wertvolle Informationen enthalten könnten. Auch auf eine Skalierung und Normalisierung wurde komplett verzichtet, da, wie schon gesagt, die Daten plausibel sind und es keine starken Ausreißer gibt, die alles verzerren könnten. Wir werden jedoch bei der Analyse und der Erstellung der Grafiken dann gezielt Skalierungen etc. verwenden.

4.3 Datentypen

Insgesamt war sehr viel Umwandlung von Datentypen notwendig, da wir Daten aus diversen Quellen und in diversen Formaten hatten. Insbesondere die Datumsformate waren sehr unterschiedlich, teilweise hatten sie Zeitstempel, teilweise waren sie Strings etc. Dies war problematisch, da wir die

Daten aus verschiedenen Quellen darauf zusammenführen wollten. Deshalb mussten diese genau im gleichen Format sein. Deshalb haben wir alle Kalenderdaten in ein Pandas «datetime» Objekt umgewandelt. Somit hatten alle Kalenderdaten das gleiche Format und die Zusammenführung bzw. die Joins wurden damit sehr simpel.

Zusätzlich haben wir die Spalte Piste 10 in eine binäre Spalte umgewandelt, da sie sehr selten einen anderen Wert als 0 erhielt und bei den Werten über 0 kein Trend erkennbar war. Somit ist es interessanter zu beobachten, ob eine generelle Nutzung der Piste 10 schon zu Verspätungen führt. Die Spalte sagt nun also aus, ob sie genutzt wurde an einem Tag oder nicht.

Wir haben alle Daten aus CSV- und Excel-Dateien mit der pandas «read_» Funktion eingelesen, pandas erkennt so von sich aus schon die Datentypen grundsätzlich sehr gut korrekt.

Generell betrachtet haben wir folgende Datentypen:

- Datetime: Kalenderdatum
- Floats: Abflugverspätung ZRH, Regen, Windgeschwindigkeit, Maximale Windgeschwindigkeit, Temperatur, Ölpreis, Schnee_intensität, weitere spätere erstelle Spalten
- Integers: Anzahl Abflüge total, alle Abflüge von Pisten (ausser Piste 10, die binär wurde)
- Booleans (True/False): Piste_10_binär, alle Spalten die anzeigen, ob Daten imputiert wurden, schnee_vorhanden, Feiertage, WEF

5. Datenintegration und Harmonisierung

5.1 Zusammenführung

Wie vorhin bereits erwähnt, war für uns die Spalte, mit welcher wir die verschiedenen Daten zusammengeführt haben, die Datumsspalte. Dies ist sinnvoll, da wir immer Daten von verschiedenen Tagen beobachten möchten und das Datum bei allen Datenquellen einheitlich ist. Als Ausgangslage haben wir den Datensatz mit den Verspätungen vom Flughafen Zürich gewählt. Dieser wurde dann mit den Abflugsdaten vom Flughafen Zürich auf den Kalenderdaten mit einem Left-Join zusammengeführt. Das heisst, alle Daten von den Verspätungen waren noch vorhanden, was jedoch problematisch war, da die Verspätungen mehr Daten hatten als nur bis zum 28.02.2026, weshalb wir mit einer Python Zeile dann alle Kalenderdaten nach dem 28.02.2026 herausgefiltert haben. Für alle weiteren Daten haben wir den Filterprozess ebenfalls wiederholt, die wir noch hinzufügen wollten.

Wir haben immer auf Left-Joins gesetzt, da es durchaus vorkommen konnte, dass der neu hinzuzufügende Datensatz fehlende Werte an einigen Tagen aufweist und wir so verhindern konnten, dass wir einige Tage verlieren.

Für das zusammenführen haben wir immer die .merge Funktion von pandas genutzt.

5.2 Harmonisierung

Neben dem Zusammenführen mussten wir die Daten auch harmonisieren, da die Quellen ganz unterschiedlich aufgebaute Daten hatten. Wichtig war es, die zeitlichen Granularitäten zu vereinheitlichen. Alle Daten wurden auf einen Tag zusammengeführt, weil wir später Tage betrachten wollten und so Daten immer einem Tag zugeordnet werden konnten.

Natürlich wurden auch Spalten umbenannt, da insbesondere die Wetterdaten sehr abstrakte Spaltennamen hatten. Unnötige Spalten, die uns nicht interessant erschienen, haben wir entfernt bzw. nicht selektiert bei der Auswahl der Spalten in Python.

Uns ist bewusst, dass wir durch die Aggregation auf Tagesebene etwas Detailtiefe verlieren, aber diese nehmen wir bewusst in Kauf, da sich die Fragestellungen auf Tage beziehen und die Daten so deutlich vergleichbarer und sauberer zusammenführbar sind.

6. Feature Engineering und Transformation

6.1 Feature-Erstellung

Wir haben diverse neue Spalten bzw. Features erstellt und verändert, da einige allein noch nicht viel aussagen konnten.

Piste 10

Wie schon vorweggenommen, haben wir die Piste 10 binär umgewandelt (True/False), ob es überhaupt einen Abflug an einem Tag gab, da es dort nur selten Abflüge gibt.

Imputation

Wie auch schon angesprochen, haben wir zusätzliche Spalten erstellt, die jeweils anzeigen, ob bei Spalten (bei welchen Daten imputiert wurden) eine gewisse Zeile verändert wurde. Somit herrscht Transparenz über die imputierten Daten.

Ölpreis

Der tagesaktuelle Ölpreis hat eine tiefe Aussagekraft, da das Flugverhalten sich wegen einer täglichen Ölpreisänderung kaum verändert. Also wäre es interessanter zu betrachten, wie sich Trends des Ölpreises auswirken, dafür haben wir folgende Spalten erstellt:

- `90_day_average_oil_price`: Zeigt den durchschnittlichen Ölpreis der letzten 90 Tage, kann also deutlich besser Trends abbilden statt tagesaktueller Ölpreise, um zu sehen, ob Ölpreise wirklich das Flugverhalten beeinflussen
- `oil_trend`: Zeigt die Differenz vom durchschnittlichen 90-tägigen Ölpreis zum durchschnittlichen 7-tägigen Ölpreis und erfasst somit, ob der Ölpreis in den letzten 7 Tagen gegenüber den letzten 90 Tagen gestiegen oder gesunken ist, ein positiver Wert bedeutet, der Ölpreis ist gestiegen
- `oil_volatility_90`: Zeigt die Standardabweichung des Ölpreises der letzten 90 Tage, davon erhoffen wir uns zu sehen, ob eine höhere Volatilität Konsumenten bzw. Airlines verunsichert und somit auch Auswirkungen auf Verspätungen hat. Der aktuelle Tag wurde von der Standardabweichung ausgeschlossen, um zu verhindern, dass tagesaktuelle Informationen diese Daten beeinflussen

Anzumerken ist, dass unsere Daten zum Ölpreis über den 01.01.2022 hinausreichten und wir deshalb schon ab dem 01.01.2022 die vergangenen 90 Tage berechnen konnten.

Monat / Wochentag

Es ist auch sehr interessant zu beobachten, welchen Einfluss der Wochentag bzw. der Monat auf die Verspätungen hat. Das Einfügen dieser Spalten war sehr einfach, weil wir schon pandas datetime Objekte hatten und jetzt nur noch mit einer Zeile Code jeweils diese beiden Spalten befüllen konnten.

6.2 Datenpipeline und Architektur

Der Datenfluss (Wrangling.py) ist als strukturierte, reproduzierbare Pipeline aufgebaut. Bei der Ausführung der Datei wird der zusammengesetzte Datensatz (merge.csv) erstellt, komplett ohne manuelle Zwischenschritte.

Jede Quelle wird aus ihrer ursprünglichen Form geladen: die Verspätungen mit `read_excel`, Wetterdaten und Ölpreise mit `read_csv`. Die Abflüge standen uns nur als PDF zur Verfügung und werden daher mit einem Skript mit `pdfplumber` in eine CSV-Datei umgewandelt, inklusive einer Logik, die automatisch überprüft, ob die Abflüge aller Pisten exakt der Anzahl Abflüge pro Tag entsprechen, um eine hohe Qualität zu gewährleisten. Die WEF-Tage werden mit einem `beautifulsoup` Scraper von Wikipedia geholt, die Feiertage über die `Library holidays` mit der Region Zürich.

Aus den Daten werden die relevanten Spalten selektiert und eindeutig benannt, zusätzlich werden alle Kalenderdaten in das gleiche `datetime` Format gebracht, um das korrekte Zusammenführen von Daten sicherzustellen. Aus den bestehenden Daten werden auch neue Spalten wie die binäre Piste 10 und unterschiedliche Spalten zu Schnee und Ölpreisen abgeleitet. Fehlende Werte werden wie in Kapitel 4 erwähnt behandelt. Abschliessend werden die Datentypen explizit gesetzt, um die Datenqualität hoch zu halten.

Als Ausgangsdatensatz dienen die Verspätungsdaten, alle weiteren Daten werden per `Left Join` auf den Kalenderdaten zusammengeführt, so gehen keine Daten verloren, wenn eine Quelle nicht alle Kalenderdaten hat. Der Zeitraum wird aufgrund der vorhandenen Daten wie schon erwähnt auf Ende Februar begrenzt. Das gesamte Ergebnis ist in `merge.csv` auffindbar, diese Datei dient als alleinige Grundlage für die Analyse.

Unsere Architektur entspricht eher einem ELT- als einem ETL-Prozess. Die Rohdaten bleiben, wie schon erwähnt, unverändert erhalten und die ganzen Transformationen finden erst nach dem Laden statt. Wir haben uns bewusst dafür entschieden, da der Datensatz verhältnismässig klein ist. Zusätzlich bleiben so die Rohdaten erhalten, weshalb wir flexibel neue Daten ableiten können.

7. Analyse

7.1 Korrelationsanalyse

Um uns zuerst einen groben Überblick zu verschaffen, wurden zwei Korrelationsanalysen erstellt. Einmal eine, welche die Korrelation der verschiedenen Daten mit den Verspätungen analysiert.


Abfluganzahl hat die stärkste Korrelation, während Feiertage nur begrenzten Einfluss haben

Abbildung 5 Korrelationen Abflüge und Feiertage

- Anzahl Abflüge: Ist logisch erklärbar, mehr Abflüge führen zu mehr Verspätungen, da der Flughafen überlastet ist
- Temperatur: Sehr interessant, logisch würde man davon ausgehen, dass tiefe Temperaturen im Winter zu mehr Verspätungen führen würden, da Enteisung von Flugzeugen notwendig ist -> genauere Analyse notwendig
- Schnee-Intensität/Schnee vorhanden: Widerlegt eigentlich genau den Faktor Temperatur, starker Schnee erhöht Verspätungen, dies ist logisch erklärbar, da Pisten geräumt werden müssen und das Enteisen von Flugzeugen notwendig ist
- Pisten: Muss genauer analysiert werden, woher die Einflüsse kommen
- Regen: Starker Regen erhöht Verspätungen, dies ist logisch erklärbar, da bei starkem Regen Abflüge verzögert werden müssen
- Monate/Wochentag: Die Korrelation allein sagt hier wenig aus, muss genauer analysiert werden
- Windspalten: Erwartbar, leichte positive Korrelationen, extrem starke Winde erhöhen die Verspätungen, dies ist logisch erklärbar, da bei sehr starken Winden Abflüge verzögert oder gar gestrichen werden müssen
- WEF/Feiertage: Tiefe Korrelation, könnte aber daher auftreten, weil diese Tage sehr selten zutreffen. Genauere Analysen wären erforderlich, insbesondere für das WEF.
- Ölpreis Spalten: Diverse leicht negative Korrelationen, müssen genauer analysiert werden

7.2 Analyse des Einflusses der Temperatur

Entgegen unseren Erwartungen führen höhere Temperaturen ($> 20\text{ °C}$) zu mehr Verspätungen als $0\text{--}20\text{ °C}$, allerdings liegt dies daran, dass im Sommer die Temperaturen höher sind und es in den Sommermonaten mehr Abflüge gibt. Einerseits lässt sich dies durch die Korrelation von 0.58 zwischen den Abflügen pro Tag und der Temperatur beweisen.




Abbildung 6 Einfluss der Temperatur auf die Verspätungen

Das obige Säulendiagramm zeigt, was die durchschnittliche Verspätung bei verschiedenen Temperaturklassen ist. Dadurch wird eindeutig ersichtlich, dass bei Temperaturen unter 0 °C die Verspätungen wieder stark anziehen, da diese niedrigen Temperaturen aufgrund des Enteisens und anderer Faktoren zu mehr Verspätungen führen.




Abbildung 7 Heatmap (Temperatur und Verspätungen)

Die Heatmap zeigt die durchschnittlichen Verspätungen bei verschiedenen Temperaturklassen aller Monate. Durch die Grafik ist zu belegen, dass in den Sommermonaten die Verspätungen unabhängig von der Temperatur ähnlich hoch sind, und in den Wintermonaten (November – Januar) ist eindeutig ersichtlich, dass niedrigere Temperaturen zu mehr Verspätungen führen als bei höheren Temperaturen. Somit kann man schlussfolgern, dass hauptsächlich sehr tiefe Temperaturen einen direkten Einfluss auf die Verspätungen haben.

7.3 Analyse des Einflusses der Nutzung der verschiedenen Pisten

Grundsätzlich ist die positive Korrelation der Nutzung der Pisten 32/34/16 interessant, weil diese die Verspätungen nach oben treiben. Da aber nicht alle Pisten täglich benutzt werden und es gut möglich ist, dass nicht lineare Zusammenhänge versteckt sind, ist auch hier eine genauere Analyse sinnvoll.

Relativ betrachtet entlastet Piste 28, während Piste 32 und 34 mit mehr Verspätung einhergehen




Abbildung 8 Nutzung von verschiedenen Pisten

Diese Scatterplots zeigen den Zusammenhang zwischen dem Anteil der Abflüge einer Piste an den Gesamtabflügen und den durchschnittlichen Abflugverspätungen. Die Verwendung absoluter Abflugzahlen ist hier weniger sinnvoll, da die Korrelation sonst durch ein allgemein höheres Verkehrsaufkommen verzerrt werden könnte. Piste 32 und 34 haben eine (leicht) positive Korrelation, ein hoher Anteil dieser Pisten führt also zu mehr Verspätungen. Piste 32 wird eigentlich täglich für Flüge morgens oder abends genutzt. Allerdings wird sie auch bei starkem Westwind genutzt (<https://www.flughafen-zuerich.ch/de/unternehmen/verantwortung/laerm-und-schallschutz/flugbetrieb/betriebskonzepte>). Für die Piste 34 gilt das Gleiche, abgesehen vom starken Westwind.




Abbildung 9 Einfluss von Wind auf die einzelnen Pisten

Das gestapelte Säulendiagramm zeigt den relativen Anteil der Pistenabflüge bei verschiedenen Windstärken. Sehr interessant ist hierbei, dass bei stärkeren durchschnittlichen Winden die Piste 32 deutlich intensiver genutzt wird als die Piste 28. Somit kann schlussgefolgert werden, dass, wenn die Piste 32 intensiv genutzt wird, ein stärkerer Wind herrscht. Spannend ist auch zu sehen, dass der Wind positiv mit den Verspätungen korreliert. Umgekehrt erklärt dies auch, dass eine intensive Nutzung der Piste 28 die Verspätungen reduziert, da dann tendenziell weniger Wind herrscht. Nun wäre es interessant herauszufinden, ob beim Wind der massgebende Faktor ist, dass die Pisten genutzt werden, oder ob bei den Pisten der massgebende Faktor ist, dass andere Pisten genutzt werden müssen.




Abbildung 10 Standardisierte Koeffizienten

Dieses horizontale Balkendiagramm zeigt die standardisierten Koeffizienten der multiplen linearen Regression und somit den eigenständigen Einfluss der einzelnen Variablen auf die durchschnittliche Abflugverspätung. Überraschenderweise ist der Koeffizient für die durchschnittliche Windgeschwindigkeit hier leicht negativ. Dies bedeutet aber nicht, dass der Wind gar keine Rolle spielt. Da Wind und Pistennutzung stark zusammenhängen (Windgeschwindigkeit und -richtung beeinflussen stark die Pistenwahl), kontrolliert die Regression diesen gemeinsamen Effekt heraus. Der Einfluss des Windes läuft also grösstenteils indirekt über die veränderte Pistennutzung, statt dass der Wind die Abflüge direkt verzögert. Tendenziell ist somit die Pistennutzung der stärkere Treiber der Verspätungen, während der Wind bestimmt, welche Pisten genutzt werden.

7.4 Analyse des Einflusses der Wochentage/Monate

Da die Korrelation allein praktisch nichts über das Verhältnis der Monate und der Wochentage zu den Verspätungen aussagt, haben wir diese noch genauer analysiert.

Jul ist der stärkste Verspätungsmonat; Flugvolumen und Verspätung hängen monatlich zusammen ($r = 0.83$)




Abbildung 11 Flugvolumen

Dieses Balkendiagramm zeigt die durchschnittliche Verspätung pro Monat sowie die durchschnittliche Anzahl Flüge täglich pro Monat. Diese Grafik erklärt auch eindeutig die positive Korrelation, die besteht, da Monate am Ende des Jahres höhere Verspätungen aufweisen. Zusätzlich kann daraus direkt herausgelesen werden, dass die Sommermonate am meisten Verspätungen aufweisen. Interessanterweise finden dann aber gar nicht deutlich mehr Flüge statt im Verhältnis zu den anderen. Also kommen die hohen Verspätungen in den Sommermonaten wohl auch daher, dass die Flüge stärker ausgelastet sind. Leider konnten wir keine öffentlichen Daten zu den monatlichen Passagierzahlen finden, um dies zu überprüfen.

Freitag hat die höchste Verspätung; über die Woche folgt sie stark dem Flugvolumen ($r = 0.76$)




Abbildung 12 Wochentage und Verspätungen

Dieses Balkendiagramm zeigt die durchschnittliche Abflugverspätung pro Wochentag sowie die durchschnittliche Anzahl Abflüge pro Wochentag. Es ist klar ersichtlich, dass die Wochentage selber einen eher geringen Einfluss haben und die höheren Verspätungen am Donnerstag, Freitag, Sonntag und Montag auf die höhere Anzahl Abflüge zurückzuführen sind.

7.5 Analyse des Einflusses des WEFs

Die ursprüngliche Korrelation ist sehr tief (leicht positiv), dies kann aber daran liegen, dass an sehr wenigen Tagen das WEF stattfand. Somit ist eine genauere Untersuchung sinnvoll.

WEF-Tage liegen im Schnitt +4.3 min über ihrem Monatsmittel




Abbildung 13 WEF Vergleich

Diese Grafik zeigt links Boxplots mit den Abweichungen von der durchschnittlichen Verspätung im Monat, während das Balkendiagramm rechts die Abweichungen der Verspätungen vom Durchschnitt in diesem Monat zeigt. Durch die beiden Grafiken kann geschlussfolgert werden, dass das WEF durchaus einen Einfluss auf die Verspätungen hat, allerdings ist der Einfluss tiefer als erwartet. Abgesehen von zwei sehr starken Ausreißern sind alle Abweichungen unter 15 Minuten, und einige Datenpunkte haben sogar niedrigere Verspätungen als der Durchschnitt in dem Monat.

7.6 Analyse des Einflusses des Ölpreises

Die Korrelationen der verschiedenen Ölpreis-Features mit den Verspätungen sind eher uninteressant, da sie sehr klein sind. Dennoch ist eine Analyse, ob es mögliche nicht lineare Zusammenhänge gibt, sinnvoll und interessant.




Abbildung 14 Einfluss von schwankenden Ölpreisen

Dieses Balkendiagramm zeigt für jeden Monat die Korrelation zwischen dem Ölpreis-Trend und den durchschnittlichen Abflugverspätungen. Positive Werte bedeuten, dass in diesem Monat steigende Ölpreis-Trends tendenziell mit höheren Verspätungen einhergingen. Aus der Grafik kann kein eindeutiger Schluss gezogen werden, vielmehr könnten die Abweichungen durch externe Effekte erklärt werden (Luftraumschliessungen, Ukraine-Krieg etc.). Auch ansonsten konnten keine Zusammenhänge mit dem Ölpreis gefunden werden. Dies liegt zu einem gewissen Grad wohl auch daran, dass über einen deutlich längeren Zeitraum betrachtet werden müsste, ob sich das Flugverhalten durch hohe Ölpreise verändert.

8. Beantwortung Fragestellungen

8.1 Beantwortung der Fragestellungen

Welche Faktoren haben den grössten Einfluss auf Verspätungen am Flughafen Zürich?

- Anzahl Abflüge pro Tag hat mit Abstand den grössten Einfluss, mehr Flüge pro Tag -> mehr Verspätungen
- Schnee und Regen führen beide zu schwierigeren Abflugbedingungen und beides führt zu mehr Verspätungen
- Die intensive Nutzung der Piste 32 aufgrund starken Windes führt zu höheren Verspätungen
- Die intensive Nutzung der Piste 28 führt zu weniger Verspätungen, da dann Normalbetrieb hinsichtlich des Windes herrscht und Flugzeuge weniger weit zur Startbahn rollen müssen
- Sehr tiefe Temperaturen (besonders unter 0 Grad) erhöhen die Verspätungen merklich
- Sommermonate führen zu höheren Verspätungen, aber tendenziell eher wegen der hohen Passagierzahl statt der Anzahl der Abflüge
- Das WEF erhöht die Verspätungen leicht an den Tagen, an welchen es stattfindet

Welche Zusammenhänge gibt es zwischen den verschiedenen Daten, die Einfluss auf die Verspätungen haben und was kann man daraus schliessen?

- Der Temperatureffekt ist verzerrt: Hohe Temperaturen führen nicht direkt zu mehr Verspätungen, sondern eher das erhöhte Passagieraufkommen an Tagen mit wärmeren Temperaturen (im Sommer)
- Wind beeinflusst hauptsächlich die Pistennutzung, welche dann die Verspätungen beeinflusst, statt die Abflüge direkt zu beeinflussen
- Wochentage und Anzahl der Abflüge hängen zusammen, an gewissen Wochentagen gibt es deutlich mehr Abflüge als an anderen, weshalb es an diesen auch eher zu mehr Verspätungen kommt

Welchen Einfluss hat das WEF tatsächlich auf Verspätungen und den Flugverkehr?

- Der Einfluss ist geringer, als man vermuten würde, einzelne Tage weisen sehr hohe Verspätungen auf, aber der durchschnittliche WEF-Tag hat nur 4 Minuten mehr Verspätung als der durchschnittliche Tag während des Monats in dem das WEF stattfindet

Was könnte der Flughafen Zürich tun, um Verspätungen an Tagen mit grosser Verspätung zu reduzieren?

- Bei starkem Wind so lange wie sicherheitstechnisch möglich von der Piste 28 fliegen
- Auf Tage mit Schnee so gut wie möglich vorbereitet sein, um den Einfluss zu reduzieren
- In den Sommermonaten mehr Personal einstellen für die Logistik im Flughafen, da die Verspätungen eher am hohen Passagieraufkommen liegen als an der Anzahl der Abflüge
- WEF-Tage gezielt vorbereiten, falls möglich

Wie gut kann ein Machine-Learning -Modell die Verspätungen tatsächlich vorhersagen?

- 3 einfache Baselines, die es zu schlagen gilt
 - Wochentag-Durchschnitt einsetzen MAE: 4.84 Min.
 - Monatsdurchschnitt einsetzen MAE: 5.06 Min.
 - Durchschnitt aller Tage einsetzen MAE: 5.07 Min.
- Gradient Boosting-Modell MAE: 3.65 Min. (Data Leakage wurde verhindert)
- Ein Machine-Learning-Modell ist also genauer, aber auch nicht perfekt

- Mit weiteren Daten wie dem Passagieraufkommen, anwesendem Personal, ATC- und Slot-Daten, und Verspätungsdaten der ankommenden Flugzeuge könnten wahrscheinlich noch deutlich bessere Resultate erzielt werden

9. Fazit und Reflexion

9.1 Zusammenfassung

In dieser Arbeit haben wir untersucht, welche Faktoren effektiv Einfluss auf die Abflugverspätungen am Flughafen Zürich haben. Dazu haben wir Daten aus diversen Quellen zusammengeführt, konkret Eurocontrol-Punctuality-Daten, Abflugdaten des Flughafens, Wetterdaten, Ölpreise, Feiertage sowie die WEF-Daten. Diese haben wir bereinigt, harmonisiert und in einer explorativen Analyse genauer angeschaut. Anschliessend haben wir mittels Korrelations- und Einflussanalysen die wichtigsten Treiber identifiziert und versucht, mit einem Machine-Learning-Modell die Verspätungen vorherzusagen.

Die Resultate zeigen, dass die Anzahl der Abflüge pro Tag mit Abstand den grössten Einfluss auf die Verspätungen hat. Wetterbedingungen wie Schnee, Regen und sehr tiefe Temperaturen erhöhen die Verspätungen ebenfalls merklich, ebenso die intensive Nutzung der Piste 32 bei starkem Wind. Der Effekt des WEFs ist hingegen kleiner als ursprünglich vermutet. Der durchschnittliche WEF-Tag hat nur rund 4 Minuten mehr Verspätung als ein durchschnittlicher Tag im gleichen Monat. Einige vermeintliche Zusammenhänge entpuppten sich zudem als verzerrt: Hohe Temperaturen führen nicht direkt zu mehr Verspätungen, sondern eher das erhöhte Passagieraufkommen in den Sommermonaten.

Unser Gradient Boosting-Modell erreicht einen MAE von 3.65 Minuten und schlägt damit alle drei einfachen Baselines (Wochentags-, Monats- und Gesamtdurchschnitt mit MAEs zwischen 4.84 und 5.07 Minuten). Damit ist eine Vorhersage möglich, aber bei weitem nicht perfekt. Mit zusätzlichen Daten wie dem Passagieraufkommen, ATC- und Slot-Daten oder den Verspätungen der ankommenden Flugzeuge liessen sich die Resultate wahrscheinlich noch deutlich verbessern.

9.2 Lessons Learned

Wir haben mit sehr vielen Daten gearbeitet, was interessant, aber auch sehr zeitaufwendig war. Das nächste Mal würden wir tendenziell die interessantesten Daten selektieren und uns auf diese fokussieren. Zudem würden wir auch die explorative Datenanalyse zu Beginn umfassender gestalten. Wir haben oft erst bei den Auswertungen gemerkt, dass gewisse Verteilungen schief sind. Ein weiteres Learning war, wie schwer es überhaupt ist, an historische Datensätze zu kommen. Oft muss dafür viel bezahlt werden oder sie sind nur sehr fragmentiert verfügbar. Wir haben sehr viel Zeit damit verbracht, unsere Quellen für den Flughafen Zürich aufzufinden. Bei einem nächsten Durchgang würden wir uns auch vorgängig überlegen, welche Daten sinnvoll sind. Eigentlich hätten wir uns denken können, dass die Ölpreise nicht sehr aussagekräftig sind, weil dafür noch sehr viele andere und historisch ältere Daten relevant wären. Auch das kritische Hinterfragen von Einflüssen erscheint uns im Nachhinein deutlich wichtiger als zu Beginn, da wir auch Korrelationen der Daten hatten, wie beim Wind und der Pistennutzung, welche nicht ignoriert werden konnten.

10. Verwendung von generativer KI

Wir haben gezielt künstliche Intelligenz verwendet, wie Codex, um Grafiken mit Python-Code erstellen zu lassen. Die Ideen für die Grafiken und die Auswertung erfolgten aber vollständig durch uns selbst. Auch die Suche und das Zusammenführen der Daten erfolgten vollständig durch uns selbst (abgesehen von dem Dokumenten-Scraper). Auch der gesamte Projektbericht wurde ohne Hilfe von generativer KI erstellt.

11. Abbildungsverzeichnis

Abbildung 1 Datensatz Statistik	9
Abbildung 2 Verspätungen Ist-Zustand	10
Abbildung 3 Histogramm Piste 10	11
Abbildung 4 Windgeschwindigkeiten	12
Abbildung 5 Korrelationen Abflüge und Feiertage	17
Abbildung 6 Einfluss der Temperatur auf die Verspätungen	18
Abbildung 7 Heatmap (Temperatur und Verspätungen)	19
Abbildung 8 Nutzung von verschiedenen Pisten	20
Abbildung 9 Einfluss von Wind auf die einzelnen Pisten	21
Abbildung 10 Standardisierte Koeffizienten	22
Abbildung 11 Flugvolumen	23
Abbildung 12 Wochentage und Verspätungen	24
Abbildung 13 WEF Vergleich	24
Abbildung 14 Einfluss von schwankenden Ölpreisen	25